Comparação de eficiência entre OpenCL e CUDA

Aluno: Thiago de Gouveia Nunes
Orientador: Prof. Marcel P. Jackowski

GPGPU

O que é GPGPU?
É programação de propósito geral em GPUs. =D

GPGPU

Existem 2 linguagens populares no mercado para GPGPU, o **CUDA** (Compute Unified Device Architecture) feita pela *NVIDIA*, e o **OpenCL** (Open Computing Language), iniciativa open source de um conjunto de empresas.

OpenCL

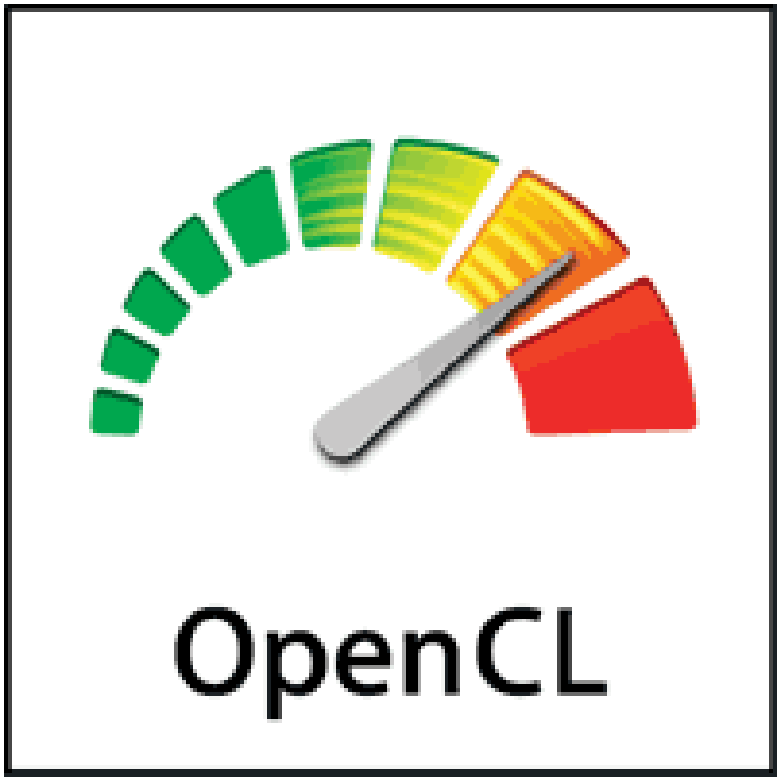

O OpenCL é uma linguagem de programação paralela para sistemas híbridos. Atualmente o OpenCL está na versão 1.2.

CUDA

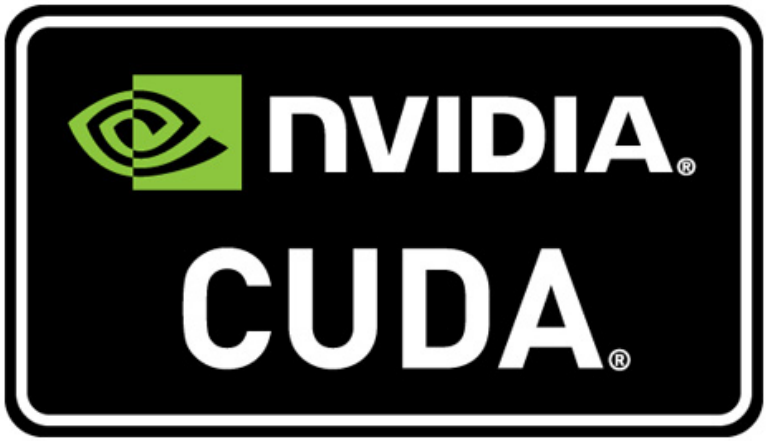

CUDA é uma linguagem proprietária para programação paralela em GPUs desenvolvida pela NVIDIA. O CUDA está na versão 5.0 atualmente.

Como comparar?

Bem, para comparar as linguagens, vamos observar 2 aspectos delas:

1. Taxa de acesso a memória;
2. Método de execução.

Para entender o impacto desses aspectos no tempo de execução, vamos dar uma olhada no hardware de uma GPU...

GPU

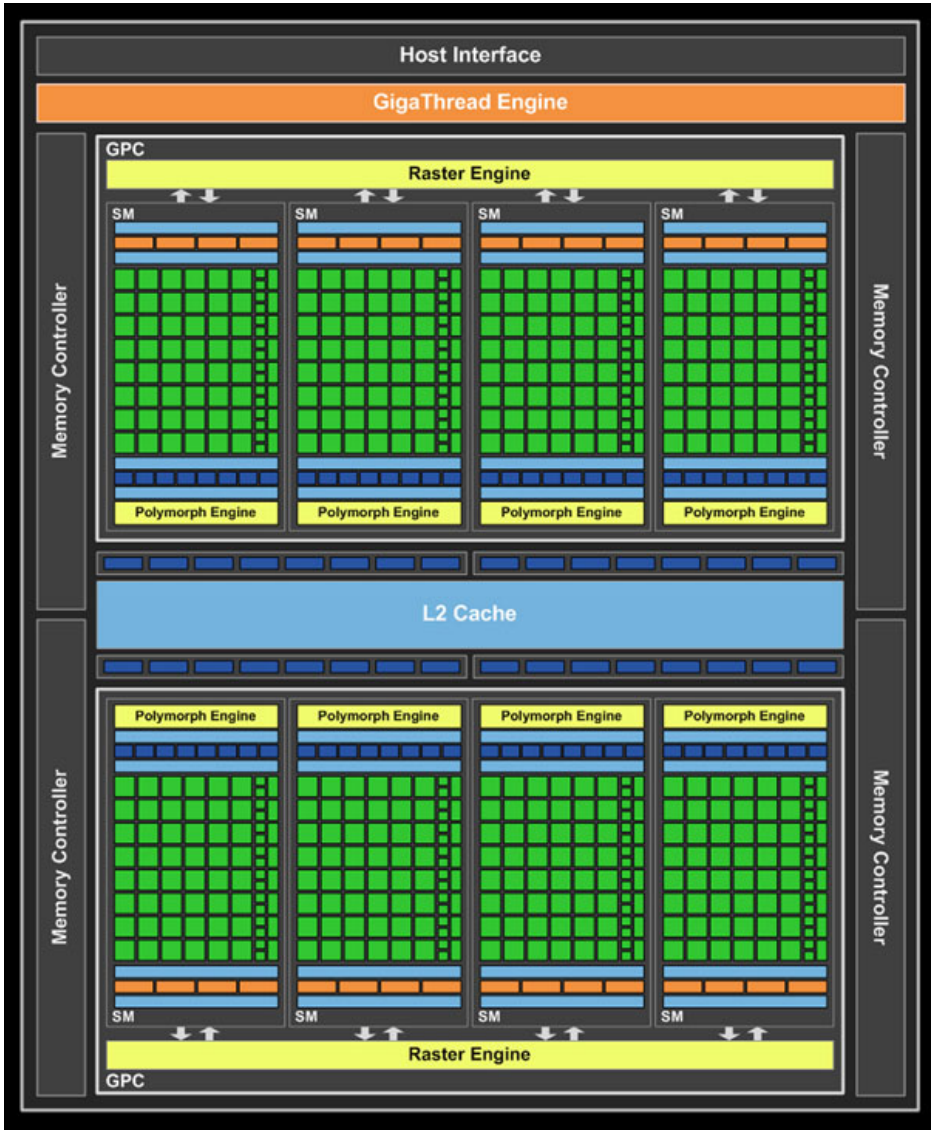

Representação do hardware de uma GTX 460 SE da NVIDIA.

Arquitetura GeForce GTX 460 SE

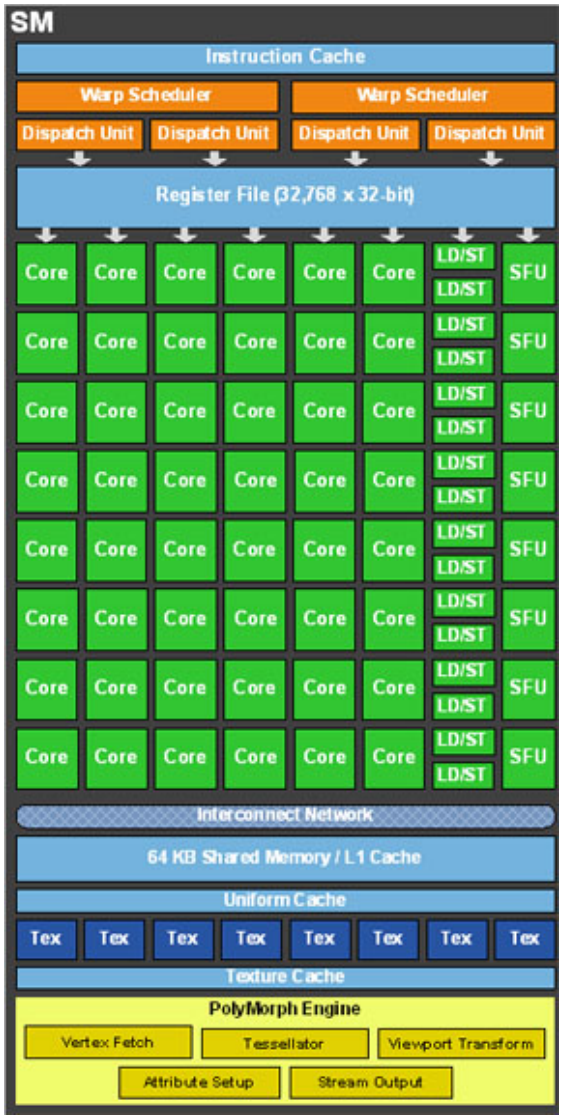

A GPU é subdividida em vários Streaming Multiprocessor, como o do lado, que agrupam 48 processadores.

Como um programa roda na GPU?

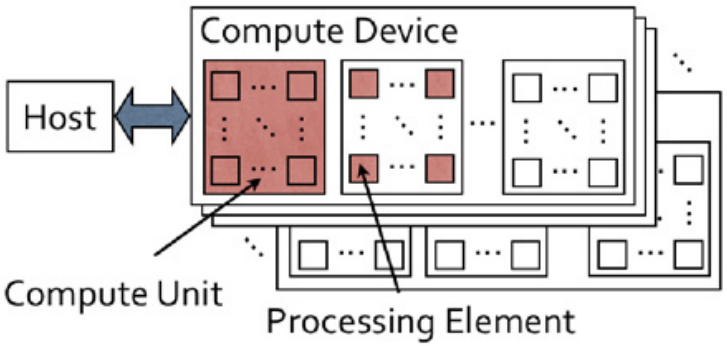

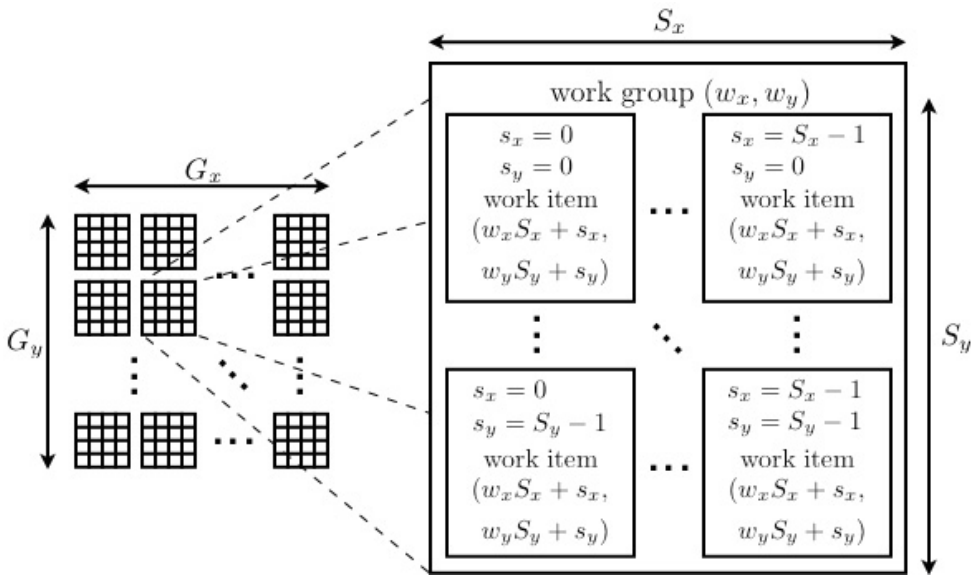

Semelhanças

Alguns elementos são iguais para as duas linguagens.

- Para iniciar a execução num device é necessario que um programa chamado de host inicie o ambiente de execução na GPU.
- As threads executando no device são identificadas por indices.
- As threads são agrupadas em conjuntos antes de serem enviadas para execução no device.
- A alocação e preenchimento da memória no device é controlada pelo host.
- A execução dos kernels pode ser síncrona ou assíncrona com o a execução do host.

Semelhanças

- Existem 4 locais diferentes para a memória que é enviada para o device:
  1. Global Memory - Toda e qualquer thread tem acesso a essa memória.
  2. Constat Memory - Memória que permanece fixa ao andar da execução.
  3. Local Memory - Região da memória dividida pelas threads de um mesmo SM.
  4. Private Memory - Região privada para cada thread.

Diferenças - Plataforma

No OpenCL existem 2 tipos de execução diferentes:

1. Data Parallel
2. Task Parallel

O CUDA implementa o modelo SIMT (*Single Instruction, Multiple Thread*).

Ideia

Para comparar a performance das duas linguagens foram usados dois tipos de kernel, um em que o desempenho está ligado ao acesso a memória (memory bound) e outro que está ligado à velocidade de processamento (compute bound).

Kernel Memory bound

Para comparar o acesso a memória, foi usado um kernel que faz a cópia de uma matriz de floats para outras.

Kernel Memory Bound

```
1   __kernel void matrixmulti(__global float* a,
        __global float* b,
3       __global int* rowSize,
        __global int* columnSize) {
5
      unsigned int row = get_global_id(0);
7     unsigned int column = get_global_id(1);

9     b[row+column*(*rowSize)]
        = a[row+column*(*rowSize)];
11  }
```

Kernel Compute bound

Para comparar o processamento, um kernel que multiplica duas matrizes de floats e guarda o valor numa terceira fui usado.

Kernel Compute bound

```
1   __kernel void matrixmulti(__global int* a,
                              __global int* b,
3                             __global int* c,
                              __global int* size) {
5       unsigned row = get_global_id(0);
        unsigned column = get_global_id(1);
7       unsigned i;

9       row *= (*size);
        c[row+column] = 0;
11      for( i = 0; i < (*size); i++ )
            c[row+column] +=
13              a[row+i]*b[i*(*size)+column];
    }
```

Estatistica Memory bound

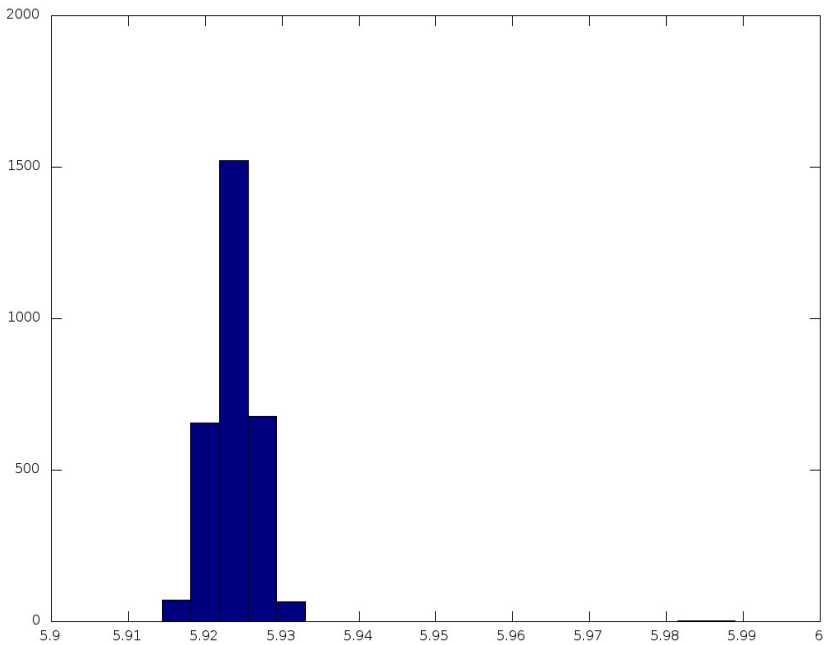

CUDA

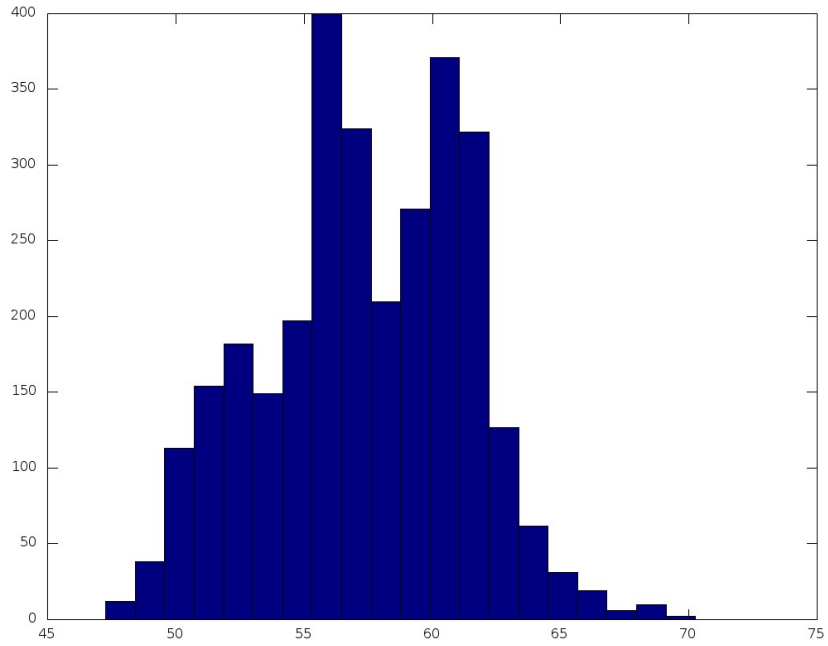

OpenCL

Estatistica Process bound

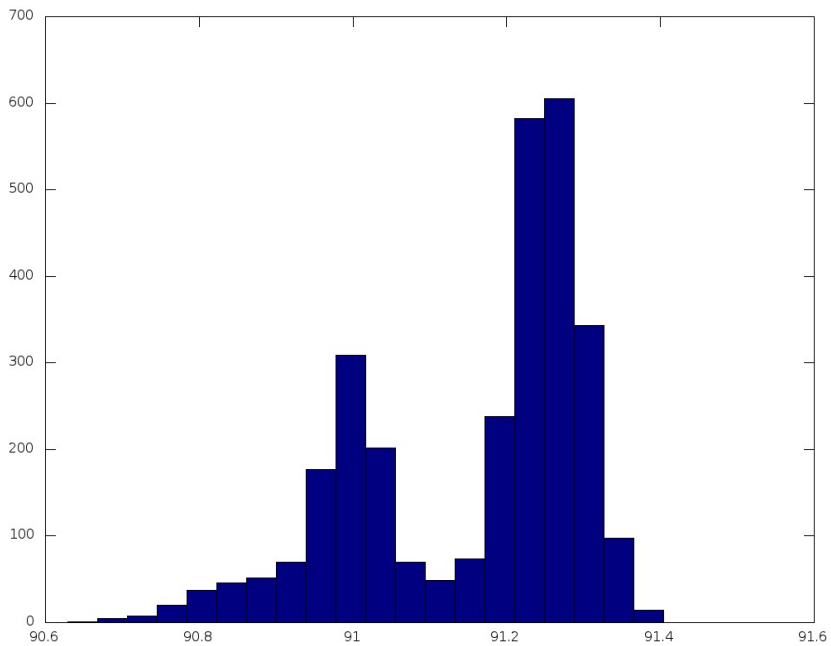

CUDA

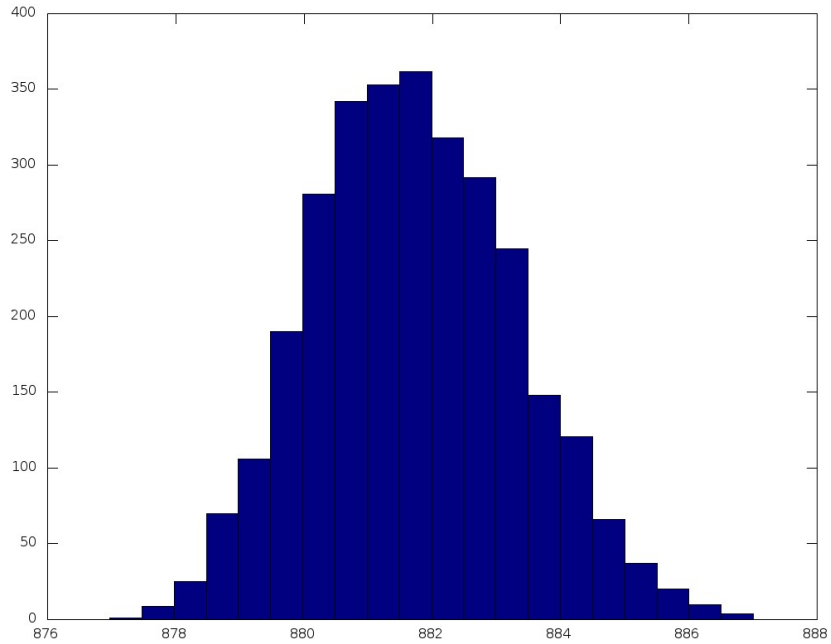

OpenCL

Explicação dos PTX

Para melhorar a compatibilidade dos programas rodando em GPUs diferentes, a NVIDIA implementou uma máquina virtual, a Parallel Thread Execution (PTX).

Arquivo .ptx

Kernel Memory Bound do CUDA Compilado para PTX

```
.reg .f32       %f<2>;
.reg .s32       %r<13>;
.reg .s64       %rl<8>;


ld.param.u64
        %rl1, [_Z10MatrixCopyPfS_ii_param_0];
ld.param.u64
        %rl2, [_Z10MatrixCopyPfS_ii_param_1];
ld.param.u32
        %r1, [_Z10MatrixCopyPfS_ii_param_3];
cvta.to.global.u64      %rl3, %rl2;
mov.u32         %r2, %ntid.x;
mov.u32         %r3, %ctaid.x;
mov.u32         %r4, %tid.x;
mad.lo.s32      %r5, %r2, %r3, %r4;
mov.u32         %r6, %ntid.y;
mov.u32         %r7, %ctaid.y;
mov.u32         %r8, %tid.y;
mad.lo.s32      %r9, %r6, %r7, %r8;
mad.lo.s32      %r10, %r5, %r1, %r9;
cvta.to.global.u64      %rl4, %rl1;
mul.wide.s32    %rl5, %r10, 4;
add.s64         %rl6, %rl4, %rl5;
add.s64         %rl7, %rl3, %rl5;
ld.global.f32   %f1, [%rl6];
st.global.f32   [%rl7], %f1;
ret;
```

Kernel Memory Bound do OpenCL Compilado para PTX

```
.reg .f32       %f<2>;
.reg .s32       %r<21>;


ld.param.u32
        %r9, [matrixmulti_param_0];
ld.param.u32
        %r10, [matrixmulti_param_1];
ld.param.u32
        %r11, [matrixmulti_param_2];
mov.u32         %r1, %envreg3;
mov.u32         %r2, %ntid.x;
mov.u32         %r3, %ctaid.x;
mov.u32         %r4, %tid.x;
add.s32         %r12, %r4, %r1;
mad.lo.s32      %r13, %r3, %r2, %r12;
mov.u32         %r5, %envreg4;
mov.u32         %r6, %ntid.y;
mov.u32         %r7, %ctaid.y;
mov.u32         %r8, %tid.y;
add.s32         %r14, %r8, %r5;
mad.lo.s32      %r15, %r7, %r6, %r14;
ld.global.u32   %r16, [%r11];
mad.lo.s32      %r17, %r15, %r16, %r13;
shl.b32         %r18, %r17, 2;
add.s32         %r19, %r9, %r18;
add.s32         %r20, %r10, %r18;
ld.global.f32   %f1, [%r19];
st.global.f32   [%r20], %f1;
ret;
```

Comparação dos PTX

Pelos .ptx é possível verificar algumas das diferenças entre as abstrações das linguagens:

1. O OpenCL usa um registrador a mais que o CUDA para calcular o indice de uma thread.
2. O OpenCL faz mais leituras da memória padrão que o CUDA.
3. O OpenCL não tem acesso a todos os comandos do PTX.

Conclusões

O CUDA é mais rápido que o OpenCL em GPUs NVIDIA...