

Comparação de Eficiência entre as plataformas OpenCL e CUDA em GPUs NVIDIA

Thiago de Gouveia Nunes

Supervisor: Prof. Doutor Marcel P. Jackowski

11 de setembro de 2012

Sumário

1	Introdução	3
1.1	Motivação	3
1.2	Objetivos	3
1.3	Problemas a serem resolvidos	3
2	Conceitos e Tecnologias	4
2.1	High-Performance Computability	4
2.2	GPU	4
2.3	CUDA	5
2.3.1	Modelo de Memória	5
2.3.2	Modelo de Execução	6
2.3.3	Modelo de Plataforma	6
2.3.4	Modelo de Programação	6
2.4	OpenCL	6
2.4.1	Modelo de Memória	6
2.4.2	Modelo de Execução	6
2.4.3	Modelo de Plataforma	6
2.4.4	Modelo de Programação	6
3	Atividades Realizadas	7
3.1	Comparação de eficiencia	7
3.1.1	Como fazer a comparação?	7
3.1.2	Montagem dos kernels	7
3.2	Comparação das abstrações	7
3.3	Comparação entre os arquivos .ptx	7
4	Resultados	8
4.1	Comparação de eficiencia	8
4.1.1	Kernel memory-bound	8
4.1.2	Kernel processing-bound	8
4.2	Comparação das abstrações	8
4.2.1	Semelhanças	8
4.2.2	Diferenças	8
4.3	Comparação dos .ptx	8
5	Conclusões	9
6	Bibliografia	10

1 Introdução

1.1 Motivação

Em Computação de Alto Desempenho (HPC) existe uma parcela de supercomputadores montados com base em placas de processamento gráfico (GPU). O termo GPGPU (General-purpose computing on graphics processing units) é usado para denotar o uso de GPUs para executar programas de mais amplo espectro.

Duas linguagens são muito utilizadas atualmente para programação em ambientes GPGPU, OpenCL (Open Computing Language) e CUDA (Compute Unified Device Architecture).

1.2 Objetivos

O objetivo do estudo é comparar a eficiência de programas escritos nessas duas linguagens rodando em uma placa NVidia GeForce GTX 460.

1.3 Problemas a serem resolvidos

Para realizar essa comparação de eficiência, devemos entender como as linguagens funcionam, suas semelhanças e diferenças, e criar um método que seja justo para comparar programas semelhantes escritos nas duas linguagens.

2 Conceitos e Tecnologias

2.1 High-Performance Computability

HPC nasceu da necessidade de poder computacional para resolver uma série de problemas, entre eles:

- Previsão climática
- Modelação molecular
- Simulações físicas
- Física quântica

Até o final dos anos 90 todos os supercomputadores tinham como base processadores vetoriais. Só no final da década seguinte, com o aumento do desempenho das GPUs, que alguns supercomputadores começaram a usar GPUs como suas fontes e processamento.

2.2 GPU

A primeira GPU foi a GeForce 256, lançada em 1999. O hardware seguia um pipeline com 2 processos, um que aplicava transformações em vértices e outro em pixels. Em 2001, a GeForce 3 trouxe o primeiro processador de vértices programável. Em 2005 a primeira GPU com um processador unificado, usado tanto para pixels como para vértices, foi lançada para o console Xbox 360. Para unificar os 2 processos do pipeline num único processador foi necessário generalizar esse processador, abrindo as portas para programas paralelos genericos executarem na GPU.

O processamento da placa usada para os testes desse trabalho, a GeForce GTX460 que usa a arquitetura Fermi. sEssa arquitetura separa o fluxo de execução baseando-se no tipo de operações que serão executadas nela. Existe um fluxo para operações gráficas e outro para operações genericas. Vamos estudar o fluxo generico abaixo.

A placa contém um escalonador implementado em hardware para threads. Ele é responsável por escalonar as threads que serão executadas nos Thread Processing Clusters (TPCs). Cada TPC tem 3 streaming multiprocessors (SM), e em cada SM existem 8 streaming-processor (SPs) e um bloco de memória compartilhada. A GeForce GTX460 tem 8 TPCs. Para os TPCs, a execução segue um padrão de multiplas intruções, multiplos dados (MIMD), e dentro dos TPCs, nos SMs, a execução segue o padrão única instrução, multiplas threads (SIMT). Nesse padrão, a mesma instrução é mandada para threads diferentes, e cada thread aplica a instrução em um conjunto de dados diferentes. O próprio hardware cuida de posiveis separações condicionais no código.

O código que será executado nos SPs é chamado de Kernel. Então, ao executar um kernel na GPU, o hardware criará threads, cada uma executando esse mesmo kernel mas com dados diferentes, e cada thread será escalonada para um SP diferente. Como as threads são distribuidas pelos SMs e TPCs varia com a linguagem usada pelo kernel.

Outra parte importante do hardware é a memória. A memória na GPU é limitada em relação à da CPU. GPUs tem, em média, 1GB de memória,

enquanto CPUs tem 4GB. Outro fator é a transferência de dados da memória principal do computador para a memória principal da GPU. A transmissão é feita por um barramento PCI Express, com velocidades de até 16GB/s, dado que o barramento esteja sendo usado somente para isso. Essa transmissão é a parte mais lenta de todo o processo de execução na GPU. Em alguns casos é mais viável fazer algumas operações de baixa eficiência numa GPU do que retornar os dados computados numa GPU para a CPU e passá-los de volta para a GPU para mais operações e retornar esses dados para a CPU. Com os dados já na memória principal da GPU, eles são copiados para os caches de cada SM por demanda.

É importante conhecer a memória física da placa para qual se está programando por que acesso a memória é um dos maiores modificadores no desempenho de um programa paralelo. O acesso a memória é concorrente, mas ao utilizar caches e leitura/escritas em blocos podemos minimizar a taxa com que leituras/escritas conflitantes são feitas. Mas ainda sim é necessário atenção ao escrever um kernel. Dada a estrutura do hardware da GPU, é melhor deixar threads que façam operações sobre posições de memória próximas no mesmo SM, assim elas podem utilizar a memória compartilhada do mesmo. que além de ser mais rápido do que buscar os dados na memória principal, não cria um padrão de buscas frequentes na memória principal, que acabaria criando uma fila de acesso das threads e diminuiria o desempenho do programa.

2.3 CUDA

Compute Unified Device Architecture (CUDA) é uma arquitetura de programação para GPUs criada pela NVIDIA. A versão 1.0 foi disponibilizada no início de 2007. Atualmente só existe um compilador para CUDA, o nvcc, e ele só dá suporte para GPUs NVIDIA.

O CUDA implementa um conjunto virtual de instruções e memória, tornando os programas retroativos. O compilador primeiro compila o código em C para um intermediário, chamado de PTX, que depois será convertido em linguagem de máquina. Na conversão do PTX para linguagem de máquina o compilador verifica quais instruções o hardware suporta e converte o código para usar as instruções corretas. Novamente, para obter o maior desempenho possível, é importante saber para qual versão o código final será compilado, pois na passagem do código de uma versão maior para uma menor não existe a garantia que o algoritmo seguirá as mesmas instruções, o compilador pode mudar um conjunto de instruções para outro menos eficiente, ou em alguns casos, algumas instruções não existem em versões mais antigas do hardware.

A inicialização dos recursos que o CUDA necessita para a comunicação com a GPU é feita no background da aplicação no momento da primeira chamada de alguma das diretivas do CUDA. Essa primeira diretiva terá um tempo maior de execução que chamadas subsequentes a mesma diretiva.

2.3.1 Modelo de Memória

No CUDA, a memória é separada em 4 locais:

- Registradores - Toda variável de uma thread fica em registradores.

- Memória Local - Memória acessível por cada thread separadamente, mas de uso pouco provável. Ela só é usada se não existe mais espaço nos registradores ou se o compilador não ter certeza sobre o tamanho de um vetor.
- Memória Compartilhada - Cada bloco de threads tem uma memória compartilhada. A memória compartilhada é separada em pequenos blocos independentes. Se uma requisição de leitura tem n endereços em n blocos diferentes, o tempo de leitura desses n endereços é igual ao tempo de leitura de 1 endereço. Caso duas leituras caiam no mesmo bloco, elas serão serializadas. A memória compartilhada fica em chips dentro dos SMs, logo seu acesso é mais rápido do que o acesso a memória global.
- Memória Global - A memória global é acessível por qualquer bloco em execução em um device. A memória global não é resetada após a execução de um kernel, então chamadas subsequentes de um mesmo kernel simplesmente leem os resultados da memória global.

GPUs com Compute Capability 2.0 acima podem alocar memória dentro do device em tempo de execução.

2.3.2 Modelo de Execução

FALAR DE COMPUTE CAPABILITY

FALAR SOBRE THREADS, BLOCOS, WARPS E GRIDS

2.3.3 Modelo de Plataforma

SOBRE INICIALIZAÇÃO DO CUDA

ALOCAÇÃO DE MEMÓRIA

INICIALIZAÇÃO DAS THREADS, KERNEL

2.3.4 Modelo de Programação

2.4 OpenCL

2.4.1 Modelo de Memória

2.4.2 Modelo de Execução

2.4.3 Modelo de Plataforma

2.4.4 Modelo de Programação

3 Atividades Realizadas

3.1 Comparação de eficiencia

3.1.1 Como fazer a comparação?

3.1.2 Montagem dos kernels

3.2 Comparação das abstrações

3.3 Comparação entre os arquivos .ptx

4 Resultados

4.1 Comparação de eficiencia

4.1.1 Kernel memory-bound

4.1.2 Kernel processing-bound

4.2 Comparação das abstrações

4.2.1 Semelhanças

4.2.2 Diferenças

4.3 Comparação dos .ptx

5 Conclusões

6 Bibliografia